

PROJETO PARA PORTFÓLIO TÉCNICO

VITOR DE TOLEDO MAGALHÃES

**PIPELINE DE INTELIGÊNCIA DE MERCADO PARA O COMÉRCIO
EXTERIOR BRASILEIRO: EXTRAÇÃO, VALIDAÇÃO E
RECONCILIAÇÃO DE DADOS PÚBLICOS APLICADOS À
MOVIMENTAÇÃO PORTUÁRIA DE SANTOS**

São Paulo

2026

VITOR DE TOLEDO MAGALHÃES

**PIPELINE DE INTELIGÊNCIA DE MERCADO PARA O COMÉRCIO
EXTERIOR BRASILEIRO: EXTRAÇÃO, VALIDAÇÃO E
RECONCILIAÇÃO DE DADOS PÚBLICOS APLICADOS À
MOVIMENTAÇÃO PORTUÁRIA DE SANTOS**

Relatório técnico-científico apresentado como documentação de projeto pessoal de portfólio em Engenharia de Dados e Automação (RPA), estruturado segundo as normas de trabalhos acadêmicos da Associação Brasileira de Normas Técnicas (ABNT), descrevendo a concepção, implementação e resultados de um pipeline de dados aplicado à reconciliação de indicadores de comércio exterior.

Área: Engenharia de Dados, Automação de Processos e Computação em Nuvem

RESUMO

Este trabalho descreve a concepção, implementação e avaliação de um pipeline automatizado de extração, validação e reconciliação de dados públicos aplicados ao comércio exterior brasileiro, tomando como estudo de caso a movimentação de cargas do Porto de Santos. O problema de pesquisa parte da constatação de que fontes públicas relevantes para inteligência de mercado — relatórios estatísticos portuários, séries cambiais, registros aduaneiros e boletins de safra agrícola — são disponibilizadas em formatos heterogêneos (documentos PDF não estruturados, APIs REST, planilhas eletrônicas), o que dificulta sua consolidação analítica sistemática. Como objetivo geral, buscou-se projetar e implementar um pipeline serverless capaz de extrair, validar e cruzar automaticamente quatro fontes públicas — Autoridade Portuária de Santos (APS), Banco Central do Brasil (Bacen), Ministério do Desenvolvimento, Indústria, Comércio e Serviços (MDIC) e Companhia Nacional de Abastecimento (CONAB) —, aplicando princípios de arquitetura em camadas (medallion architecture) e mecanismos de governança de qualidade de dados. A metodologia adotada combina técnicas de automação robótica de processos (RPA) para extração de dados não estruturados, contratos de dados formais (data contracts) implementados com a biblioteca Pydantic, e uma arquitetura de computação serverless na Amazon Web Services (AWS), fundamentada em função Lambda orquestrada por Amazon EventBridge. Como mecanismo original de controle de qualidade, propõe-se um sistema de quarentena de dados com dupla verificação de integridade (circuit breakers), avaliando tanto a taxa de rejeição por registro quanto a cobertura de volume físico em relação ao total oficial declarado pela fonte primária. Os resultados demonstram a viabilidade técnica da abordagem: em execução de produção referente ao período de maio de 2026, o pipeline processou com sucesso 117.451 registros de balança comercial, 20 cotações cambiais diárias, 3.527 linhas de boletim de safra e a movimentação física do porto, com tempo total de execução de aproximadamente 70 segundos e custo operacional compatível com o nível gratuito dos serviços utilizados. A reconstrução de uma série histórica de oito anos (2019-2026), totalizando 8.860.902 registros de balança comercial, permitiu ainda a avaliação estatística preliminar das hipóteses de análise formuladas: a correlação entre volume físico exportado e cotação cambial mostrou-se fraca (0,09 a 0,17), corroborando a predominância de um padrão sazonal claro (coeficiente de variação de 14,7% entre meses do ano) sobre o efeito cambial de curto prazo, enquanto a comparação entre volume físico portuário e valor financeiro declarado revelou uma limitação estrutural de comparabilidade geográfica não antecipada na formulação inicial do problema. Discute-se, adicionalmente, um conjunto de descobertas metodológicas

relevantes obtidas ao longo do desenvolvimento — entre elas, a identificação de uma falha sistemática de extração tabular relacionada à largura variável de valores numéricos, uma cadeia de certificação TLS incompleta na fonte primária de dados, e uma lacuna de cobertura temporal na camada de origem agrícola causada por restrição de acesso ao conteúdo e duplicidade de publicação na fonte CONAB —, bem como as limitações do modelo atual, incluindo a natureza estática do modelo de alocação geográfica de produção agrícola. Conclui-se que a arquitetura proposta constitui uma base metodológica replicável para a construção de produtos de dados públicos confiáveis, com trabalhos futuros direcionados à avaliação da modelagem dimensional física e à incorporação de fontes adicionais de comparação setorial.

Palavras-chave: Engenharia de Dados. Automação Robótica de Processos. Arquitetura Serverless. Comércio Exterior. Qualidade de Dados.

ABSTRACT

This work describes the design, implementation, and evaluation of an automated pipeline for extracting, validating, and reconciling public data related to Brazilian foreign trade, using cargo movement at the Port of Santos as a case study. The research problem stems from the observation that public sources relevant to market intelligence — port statistical reports, exchange rate series, customs records, and agricultural harvest bulletins — are made available in heterogeneous formats (unstructured PDF documents, REST APIs, spreadsheets), which hinders their systematic analytical consolidation. As a general objective, this work sought to design and implement a serverless pipeline capable of automatically extracting, validating, and cross-referencing four public sources — the Santos Port Authority (APS), the Central Bank of Brazil (Bacen), the Ministry of Development, Industry, Trade and Services (MDIC), and the National Supply Company (CONAB) — applying medallion architecture principles and data quality governance mechanisms. The adopted methodology combines robotic process automation (RPA) techniques for unstructured data extraction, formal data contracts implemented with the Pydantic library, and a serverless computing architecture on Amazon Web Services (AWS), based on an AWS Lambda function orchestrated by Amazon EventBridge. As an original data quality control mechanism, a data quarantine system with dual integrity verification (circuit breakers) is proposed, evaluating both the record-level rejection rate and physical volume coverage relative to the official total declared by the primary source. The results demonstrate the technical feasibility of the approach: in a production run referring to May 2026, the pipeline successfully processed 117,451 trade balance records, 20 daily exchange rate quotations, 3,527 harvest bulletin rows, and port physical movement data, with a total execution time of approximately 70 seconds and operational cost compatible with the free tier of the services used. Additionally, the reconstruction of an eight-year historical series (2019-2026), totaling 8,860,902 trade balance records, enabled a preliminary statistical evaluation of the analysis hypotheses: the correlation between physical export volume and exchange rate proved weak (0.09 to 0.17), corroborating the predominance of a clear seasonal pattern (14.7% coefficient of variation across calendar months) over any short-term exchange rate effect, while the comparison between physical port volume and declared financial value revealed a structural geographic comparability limitation not anticipated in the initial problem formulation. Additionally, a set of relevant methodological findings obtained during development are discussed — including the identification of a systematic tabular extraction failure related to the variable width of numeric values, an incomplete TLS certificate chain at

the primary data source, and a temporal coverage gap in the agricultural origin layer caused by restricted content access and duplicate publication at the CONAB source — as well as the limitations of the current model, including the static nature of the agricultural production geographic allocation model. It is concluded that the proposed architecture constitutes a replicable methodological basis for building reliable public data products, with future work directed toward evaluating physical dimensional modeling and the incorporation of additional sector comparison sources.

Keywords: Data Engineering. Robotic Process Automation. Serverless Architecture. Foreign Trade. Data Quality.

SUMÁRIO

RESUMO3

ABSTRACT 5

SUMÁRIO.....7

1 INTRODUÇÃO.....9

 1.1 Problema de Pesquisa9

 1.2 Objetivos..... 10

 1.3 Justificativa..... 10

2 REFERENCIAL TEÓRICO..... 11

 2.1 Arquitetura de Dados em Camadas (Medallion Architecture) 11

 2.2 Automação Robótica de Processos e Extração de Documentos Não Estruturados 11

 2.3 Contratos de Dados e Governança de Qualidade 11

 2.4 Computação Serverless e Otimização de Custo Operacional..... 12

3 METODOLOGIA..... 13

 3.1 Arquitetura Geral do Sistema 13

 3.2 Fontes de Dados Integradas 14

 3.3 Organização do Pipeline por Camada 14

 3.4 Estratégia de Qualidade de Dados: Quarentena com Circuit Breaker Duplo..... 15

 3.5 Mecanismos de Resiliência e Observabilidade 16

 3.6 A Dificuldade Metodológica do Backfill Histórico 17

4 RESULTADOS 19

 4.1 Execução de Produção — Referência Maio de 2026 19

 4.2 Achados Técnicos Relevantes 19

 4.2.1 Dependência da Largura Numérica na Inferência de Colunas Tabulares 19

 4.2.2 Cadeia de Certificação TLS Incompleta na Fonte Primária 20

 4.3 Custo Operacional 20

 4.4 Reconstrução da Série Histórica e Validação Empírica das Hipóteses de Análise 21

4.4.1 Hipótese H1: Predominância da Sazonalidade sobre o Efeito Cambial	21
4.4.2 Hipótese H2: Divergência entre Volume Físico e Valor Financeiro Declarado	21
5 DISCUSSÃO E LIMITAÇÕES	23
5.1 Modelo Estático de Alocação Geográfica Agrícola	23
5.2 Cobertura Semântica Incompleta da Tabela de Correspondência De-Para.....	23
5.3 Camada de Apresentação por Views em Lugar de Modelagem Dimensional Física.....	23
5.4 Alcance e Limites da Validação Estatística Realizada.....	24
5.5 Integração Pendente com a Agência Nacional de Transportes Aquaviários	25
5.6 Gestão de Segredos de Configuração	25
5.7 Ausência de Mecanismo de Retomada Automática do Backfill	25
5.8 Cobertura Irregular da Camada de Origem Agrícola por Inconsistência da Fonte CONAB	25
6 CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS	27
REFERÊNCIAS	29

1 INTRODUÇÃO

O comércio exterior brasileiro depende de um conjunto disperso de fontes de dados públicas — autoridades portuárias, órgãos monetários, agências aduaneiras e institutos de pesquisa agropecuária — que, embora individualmente confiáveis, raramente são publicadas em formatos interoperáveis entre si. O Porto de Santos, maior complexo portuário da América Latina em volume movimentado, disponibiliza mensalmente um relatório estatístico consolidado (Mensário Estatístico) exclusivamente em formato PDF, um formato historicamente projetado para leitura humana e não para consumo automatizado (RAMALHO; NEVES, 2021). Paralelamente, o Banco Central do Brasil, o Ministério do Desenvolvimento, Indústria, Comércio e Serviços e a Companhia Nacional de Abastecimento disponibilizam dados correlatos — respectivamente, séries cambiais, registros de balança comercial e boletins de safra agrícola — por meio de interfaces de programação (API) ou arquivos estruturados, cada qual com sua própria cadência de publicação, convenção de nomenclatura e modelo de dados.

Essa fragmentação impõe um custo de integração relevante a qualquer iniciativa de inteligência de mercado que dependa da reconciliação sistemática dessas fontes — seja em ambiente corporativo (tradings de commodities, instituições financeiras, consultorias) seja em contexto de pesquisa aplicada. O problema não é apenas de acesso ao dado, mas de manutenção de sua confiabilidade ao longo do tempo: documentos como o Mensário Estatístico da APS não seguem um contrato de formatação estável, e pequenas variações de layout entre edições mensais podem comprometer silenciosamente pipelines de extração baseados em heurísticas simples de posicionamento textual, como demonstrado nos resultados deste trabalho.

1.1 Problema de Pesquisa

Diante do exposto, este trabalho parte da seguinte questão: é possível construir um pipeline automatizado, tecnicamente resiliente e operacionalmente sustentável, capaz de extrair, validar e reconciliar dados públicos heterogêneos de comércio exterior, preservando a integridade referencial entre fontes e sinalizando de forma confiável eventuais falhas estruturais na extração, sem depender de intervenção manual contínua?

1.2 Objetivos

O objetivo geral deste trabalho é projetar, implementar e avaliar um pipeline de dados serverless para extração, validação e reconciliação de indicadores públicos de comércio exterior brasileiro, tomando como estudo de caso a movimentação de cargas do Porto de Santos.

Como objetivos específicos, define-se:

- Implementar mecanismos de extração de dados não estruturados (RPA) resilientes a variações de formatação em documentos PDF governamentais;
- Estabelecer contratos de dados formais (data contracts) capazes de detectar e bloquear automaticamente desvios de schema (data drift) antes da propagação para camadas analíticas;
- Projetar um mecanismo de controle de qualidade de dados sensível não apenas à quantidade, mas à representatividade econômica dos registros rejeitados;
- Avaliar a viabilidade técnica e econômica de uma arquitetura serverless para execução de baixa frequência (mensal) em ambiente de nuvem pública;
- Documentar, de forma reproduzível, as decisões de arquitetura e as descobertas técnicas obtidas ao longo da implementação.

1.3 Justificativa

A relevância deste trabalho é dupla. Do ponto de vista prático, a reconciliação entre volume físico movimentado (fonte portuária) e valor financeiro declarado (fonte aduaneira), ajustada por variação cambial e contextualizada por sazonalidade agrícola, é uma capacidade analítica de valor direto para instituições financeiras, tradings de commodities e consultorias de inteligência de mercado. Do ponto de vista metodológico, o trabalho contribui ao documentar, com evidência empírica, falhas de extração não triviais — como a dependência da largura numérica na inferência de colunas tabulares — que raramente são discutidas na literatura aplicada de engenharia de dados, mas que têm impacto direto na confiabilidade de qualquer pipeline que dependa de documentos governamentais como fonte primária.

2 REFERENCIAL TEÓRICO

2.1 Arquitetura de Dados em Camadas (Medallion Architecture)

A organização de dados em camadas progressivas de refinamento — comumente denominadas bronze, silver e gold — constitui um padrão consolidado em arquiteturas de data lake modernas (DATABRICKS, 2023). A camada bronze preserva os dados em seu formato bruto, exatamente como recebidos da fonte primária, servindo como registro auditável e ponto de reprocessamento. A camada silver aplica limpeza, tipagem e validação estrutural, produzindo tabelas confiáveis por fonte, ainda sem cruzamento entre domínios. A camada gold, por fim, concentra a lógica de negócio propriamente dita — cruzamentos, agregações e modelagem dimensional orientada ao consumo analítico. Neste trabalho, essa separação foi adotada como princípio organizador de todo o pipeline, com implicações diretas sobre onde cada tipo de falha deve ser detectado e contida.

2.2 Automação Robótica de Processos e Extração de Documentos Não Estruturados

A Automação Robótica de Processos (RPA) refere-se ao uso de software para replicar ações humanas na interação com sistemas digitais, incluindo a navegação em portais web e a extração de informações de documentos não estruturados (VAN DER AALST; BICHLER; HEINZL, 2018). No contexto deste trabalho, a extração de tabelas de documentos PDF — realizada por meio da biblioteca pdfplumber — constitui uma forma de RPA aplicada à leitura de relatórios governamentais, e está sujeita a uma classe específica de fragilidade: a inferência de estrutura tabular a partir de posicionamento geométrico do texto, que pode ser afetada por variações de formatação não previstas no momento da implementação inicial.

2.3 Contratos de Dados e Governança de Qualidade

O conceito de contrato de dados (data contract) formaliza o schema esperado de um conjunto de dados como uma interface explícita entre produtor e consumidor, permitindo a detecção automatizada de desvios estruturais (data drift) antes que dados inválidos se propaguem por um pipeline (O'REILLY, 2022 apud LEFEBVRE, 2023). Neste trabalho, contratos de dados foram implementados por meio da biblioteca Pydantic, que permite a

definição declarativa de tipos, validadores customizados e regras de negócio no nível de campo. Complementarmente, adota-se o conceito de circuit breaker — originário da engenharia de software resiliente (NYGARD, 2018) — como mecanismo de interrupção automática de um fluxo de processamento quando um limiar de erro predefinido é ultrapassado, aplicado neste trabalho não apenas à contagem de registros rejeitados, mas à representatividade econômica desses registros em relação ao volume total declarado pela fonte primária.

2.4 Computação Serverless e Otimização de Custo Operacional

A computação serverless, exemplificada pelo serviço AWS Lambda, permite a execução de código sob demanda sem provisionamento contínuo de infraestrutura, com cobrança proporcional ao tempo e à memória efetivamente consumidos (AMAZON WEB SERVICES, 2024). Para cargas de trabalho de baixa frequência de execução — como pipelines de atualização mensal —, essa característica apresenta vantagem econômica relevante em comparação a arquiteturas baseadas em contêineres de longa duração ou máquinas virtuais permanentemente provisionadas, especialmente quando a execução não requer acesso a recursos de rede privada (Virtual Private Cloud), cenário em que a computação serverless evita integralmente o custo fixo associado a gateways de tradução de endereço de rede (NAT Gateway).

3 METODOLOGIA

Este trabalho adota abordagem de pesquisa aplicada e desenvolvimento experimental (design science research), na qual o artefato construído — o próprio pipeline de dados — constitui simultaneamente o objeto de estudo e o instrumento de validação das hipóteses de arquitetura formuladas. As subseções seguintes descrevem a arquitetura geral do sistema, as fontes de dados integradas, a organização do pipeline por camada e a estratégia de qualidade de dados adotada.

3.1 Arquitetura Geral do Sistema

A arquitetura implementada é orientada a eventos e integralmente serverless, estruturada em torno de uma função AWS Lambda única, empacotada como imagem de contêiner (Docker), com 2.048 MB de memória alocada e tempo limite de 900 segundos. A execução é acionada mensalmente por uma regra do Amazon EventBridge, configurada para o décimo quinto dia de cada mês — data em que, empiricamente, o Mensário Estatístico da APS referente ao mês anterior já se encontra publicado.

A escolha de uma função Lambda em detrimento de um contêiner de execução prolongada (Amazon ECS/Fargate) — arquitetura inicialmente cogitada durante o desenvolvimento — foi justificada por três fatores técnico-econômicos observados empiricamente: primeiro, a execução completa do pipeline consome aproximadamente 70 segundos e 616 MB de memória de pico, valores confortavelmente dentro dos limites do serviço; segundo, por não requerer acesso a uma Virtual Private Cloud, a função Lambda dispensa integralmente a necessidade de um NAT Gateway, componente que representaria custo fixo mensal desproporcional a uma execução única por mês; terceiro, o consumo mensal estimado de aproximadamente 143 GB-segundos de computação está substancialmente abaixo do limite gratuito mensal de 400.000 GB-segundos oferecido pelo provedor, tornando a operação do pipeline financeiramente sustentável em regime de nível gratuito (free tier).

O provisionamento da função e da regra de agendamento é realizado por meio do AWS Serverless Application Model (SAM), descrito declarativamente em arquivo de infraestrutura como código (template.yaml). A ferramenta Terraform, originalmente cogitada para o provisionamento, foi descartada por apresentar complexidade de configuração desproporcional à escala do projeto, conduzido por desenvolvedor único.

3.2 Fontes de Dados Integradas

Fonte	Instituição	Formato de acesso	Cadência
APS	Autoridade Portuária de Santos	Documento PDF (Mensário Estatístico)	Mensal
Bacen	Banco Central do Brasil	API pública (SGS/Olinda, PTAX)	Diária
MDIC	Ministério do Desenvolvimento, Indústria, Comércio e Serviços	API pública (Comex Stat)	Mensal
CONAB (opcional)	Companhia Nacional de Abastecimento	Planilha eletrônica (boletim de safra)	Sazonal, irregular

A tabela acima resume as quatro fontes efetivamente integradas ao pipeline no momento da avaliação. Uma quinta fonte, a Agência Nacional de Transportes Aquaviários (ANTAQ), foi identificada como relevante para fins de comparação de participação de mercado entre portos, porém permanece pendente de integração em razão de instabilidade observada em sua interface de consulta durante o período de desenvolvimento, conforme discutido na Seção 5.

A fonte CONAB, ao contrário das demais, foi tratada como opcional na arquitetura do pipeline, e não como obrigatória: sua ausência ou falha em determinado período não interrompe o processamento das demais fontes, tampouco aciona os mecanismos de circuit breaker descritos na Seção 3.4. Essa decisão de design decorre de inconsistências reiteradas observadas na publicação de boletins pela própria CONAB — incluindo períodos em que o conteúdo é sinalizado pela plataforma como "conteúdo restrito" no momento da consulta automatizada, e ao menos um caso identificado de publicação duplicada (dois boletins distintos disponibilizados para o mesmo ano de referência, 2023) —, tornando a fonte estruturalmente menos confiável em disponibilidade do que as demais integrações deste trabalho, por razões alheias à arquitetura do pipeline.

Cabe destacar que a extração dos dados da APS constitui o componente de maior fragilidade técnica do sistema, por depender da inferência geométrica de estrutura tabular a partir de um documento PDF sem contrato de formatação garantido — em contraste com as demais fontes, que expõem interfaces estruturadas e, portanto, menos suscetíveis a variação não anunciada de schema.

3.3 Organização do Pipeline por Camada

Cada fonte de dado percorre três estágios de processamento, mapeados às camadas bronze, silver e gold descritas na Seção 2.1:

- Bronze: persistência do dado bruto — arquivo PDF, resposta JSON de API ou planilha — sem qualquer transformação, no Amazon S3 (ou sistema de arquivos local, quando executado fora do ambiente de nuvem, por meio de um componente de abstração de armazenamento que alterna automaticamente entre os dois backends conforme variável de ambiente);
- Silver: aplicação dos contratos de dados Pydantic, limpeza de formatação numérica (padrão brasileiro de milhar e decimal), tipagem e gravação em formato colunar Parquet, particionado por ano;
- Gold: cruzamento entre fontes — enriquecimento da movimentação portuária com a taxa cambial do período, reconciliação com os registros de balança comercial do MDIC, e alocação geográfica de origem agrícola por meio de tabela de correspondência semântica (De-Para) entre mercadoria e cultura agrícola.

Sobre as tabelas fato da camada gold, foi construída uma camada adicional de apresentação semântica, materializada como views SQL no Amazon Athena (`vw_mdic_resumo_mensal`, `vw_mdic_top_paises`, `vw_mdic_top_capitulo`, `vw_origem_agricola_export`), responsável por pré-agregar os volumes granulares — na tabela de balança comercial, 8.860.902 linhas — em resumos mensais, rankings de país por função de janela (`DENSE_RANK`) e agrupamentos por capítulo da Nomenclatura Comum do Mercosul (NCM), consumidos diretamente pelo dashboard de Business Intelligence (Seção 4). Importa distinguir essa camada de apresentação de uma modelagem dimensional em esquema estrela (star schema) no sentido estrito: as views operam sobre a mesma tabela fato desnormalizada, na qual atributos descritivos (nome do país, código NCM completo) são armazenados por extenso em cada linha, em vez de referenciados por chave a tabelas de dimensão físicas segregadas. A distinção é discutida como limitação na Seção 5.3.

3.4 Estratégia de Qualidade de Dados: Quarentena com Circuit Breaker Duplo

Um dos aspectos metodológicos originais deste trabalho é o desenho do mecanismo de controle de qualidade da camada silver. A abordagem convencional de tratamento de erro em pipelines de ingestão apresenta usualmente duas políticas polarizadas: interrupção total do processamento diante de qualquer registro inválido (fail-fast), preservando a integridade absoluta do conjunto de dados ao custo de fragilidade operacional; ou descarte silencioso de

registros inválidos (skip-and-log), preservando a disponibilidade do pipeline ao custo de perda de dado não sinalizada.

Neste trabalho, adotou-se uma terceira abordagem, fundamentada em dois mecanismos de interrupção automática (circuit breakers) operando de forma independente e complementar:

- Circuit breaker de linha: interrompe o processamento quando a proporção de registros rejeitados sobre o total de registros processados excede um limiar predefinido, sinalizando degradação estrutural generalizada;
- Circuit breaker de cobertura de volume: interrompe o processamento quando o volume físico (em toneladas) efetivamente validado divergir do total oficial declarado pelo próprio documento fonte além de um limiar de tolerância, sinalizando que a extração pode ter capturado uma tabela ou seção incorreta do documento, ainda que os registros individuais sejam formalmente válidos.

A justificativa para o segundo mecanismo decorre de uma limitação identificada empiricamente no primeiro: a rejeição de poucas linhas de alto peso econômico (por exemplo, um único registro referente à exportação de soja) pode representar parcela substancial do volume total movimentado, sem que a taxa de rejeição por contagem de linhas — métrica adotada isoladamente pelo primeiro mecanismo — capture essa relevância. Os registros rejeitados por qualquer um dos dois mecanismos são preservados em uma zona de quarentena estruturalmente independente das camadas bronze, silver e gold, contendo o conteúdo bruto da linha rejeitada, a página e o índice de origem no documento, e a mensagem de validação específica que motivou a rejeição — viabilizando auditoria forense posterior sem necessidade de reprocessamento do documento original.

3.5 Mecanismos de Resiliência e Observabilidade

A comunicação com fontes externas (extração web e chamadas de API) é protegida por padrão de repetição automática com espera exponencial (retry pattern), implementado por meio da biblioteca Tenacity, restrito a classes específicas de exceção transitória (falhas de rede, códigos de resposta 5xx), de modo a evitar novas tentativas diante de erros estruturais não recuperáveis. O monitoramento operacional do pipeline é realizado por meio de notificações automáticas enviadas a um canal do Slack, via webhook configurado por variável de ambiente, cobrindo tanto a finalização bem-sucedida de cada etapa quanto falhas críticas. A propagação

de código de saída (exit code) do processo, essencial para que o ambiente de orquestração (Amazon EventBridge, por meio do CloudWatch) detecte falhas de execução, foi implementada explicitamente em cada etapa do pipeline.

3.6 A Dificuldade Metodológica do Backfill Histórico

O pipeline de produção descrito nas seções anteriores foi originalmente concebido para processar um único período de referência por execução (o mês corrente), com política de interrupção imediata (fail-fast) diante de qualquer falha em qualquer fonte. A reconstrução de uma série histórica de oito anos (2019-2026) para viabilizar a análise estatística apresentada na Seção 4 exigiu, no entanto, uma adaptação metodológica não trivial, materializada em uma ramificação (branch) de desenvolvimento específica (feat/historical-backfill), estruturalmente distinta do pipeline mensal em três aspectos.

Em primeiro lugar, nenhuma das quatro fontes de dados garante contratualmente uma data de início de disponibilidade histórica uniforme entre si. Para determinar de forma empírica, e não presumida, o período comum de cobertura, foi implementado um script de sondagem (discover_backfill_start.py) que testa, mês a mês a partir de um piso de referência, a disponibilidade de dado válido em cada fonte isoladamente, definindo o início do backfill como o máximo entre os pisos individuais encontrados e um piso mínimo de segurança de negócio (janeiro de 2019) — e não como uma data arbitrariamente escolhida a priori.

Em segundo lugar, a política de tratamento de erro foi deliberadamente revista para o cenário de backfill. Enquanto a execução mensal de produção interrompe integralmente o processo diante da primeira falha (adequado a uma execução isolada, onde a intervenção humana é esperada e barata), o orquestrador de backfill isola as falhas por fonte e por período, prosseguindo para o lote seguinte mesmo quando uma fonte específica falha em um mês específico, e reportando o conjunto de falhas acumuladas ao final de cada lote mensal via notificação — evitando que uma única falha pontual, em um universo de aproximadamente noventa lotes mensais, interrompesse a reconstrução da série inteira. Ausência de boletim publicado pela CONAB em determinado mês foi explicitamente tratada como resultado esperado, e não como falha, distinção que não existia — nem precisava existir — na versão mensal do pipeline.

Em terceiro lugar, a execução prolongada de dezenas de lotes sequenciais introduziu uma preocupação de governança ausente na execução mensal: um intervalo de resfriamento de cinco segundos entre lotes foi adicionado para reduzir a frequência agregada de requisições às fontes públicas ao longo da execução completa, princípio de coleta responsável já adotado neste trabalho (Seção 3.5) e reforçado nesse contexto de volume de requisições substancialmente maior. Observa-se, como limitação reconhecida dessa implementação, a ausência de um mecanismo automático de retomada a partir do último lote processado com sucesso em caso de interrupção da execução completa — discutida na Seção 5.7.

4 RESULTADOS

4.1 Execução de Produção — Referência Maio de 2026

O pipeline foi executado com sucesso em ambiente de produção (AWS Lambda) para o período de referência de maio de 2026, com os volumes de dados processados e persistidos na camada silver apresentados na Tabela 2. O tempo total de execução, do início da extração ao término da consolidação da camada gold, foi de 69,4 segundos, com pico de utilização de memória de 616 MB — dentro da margem de segurança em relação à capacidade alocada (2.048 MB), sem indício de risco de esgotamento de recursos para os volumes observados.

Fonte	Registros extraídos	Registros validados (silver)	Taxa de rejeição
APS (movimentação portuária)	30	30	0,00%
Bacen (PTAX)	20	20	0,00%
MDIC (Comex Stat)	117.451	117.451	0,00%
CONAB (safra agrícola)	135	135	0,00%

A ausência de rejeições na execução de referência indica estabilidade estrutural das quatro fontes no período avaliado, mas não deve ser interpretada como evidência de robustez plena do sistema — conforme discutido na Seção 4.2, falhas estruturais não triviais já foram identificadas e corrigidas em execuções anteriores, precisamente pelos mecanismos de circuit breaker aqui descritos.

4.2 Achados Técnicos Relevantes

Ao longo do desenvolvimento, dois achados técnicos específicos merecem registro pela sua relevância metodológica para a confiabilidade de pipelines baseados em documentos governamentais.

4.2.1 Dependência da Largura Numérica na Inferência de Colunas Tabulares

A estratégia inicial de extração tabular do documento da APS baseava-se na inferência de limites de coluna a partir da posição horizontal de caracteres de texto na página (estratégia textual). Essa abordagem mostrou-se sistematicamente frágil frente a variações na largura dos valores numéricos: em meses do ano com totais acumulados mais extensos (dígitos adicionais), a posição horizontal do texto se deslocava suficientemente para corromper a segmentação de

colunas, fragmentando inclusive a etiqueta identificadora da linha de totalização geral ('TOTAL GERAL') em duas células distintas ('TOTAL' e 'GERAL'), e concatenando valores numéricos adjacentes em uma única célula. Esse comportamento foi confirmado empiricamente, de forma reproduzível, tanto no documento referente a janeiro quanto ao de maio de 2026, por meio de inspeção direta da extração com instrumentação diagnóstica. A correção adotada substituiu a inferência textual pela leitura das linhas de grade vetoriais efetivamente presentes no documento (estratégia geométrica), eliminando a dependência da largura do conteúdo numérico e restaurando a segmentação correta de colunas em ambos os documentos testados.

4.2.2 Cadeia de Certificação TLS Incompleta na Fonte Primária

Durante a implementação do extrator da APS, identificou-se falha de verificação de certificado TLS (`SSL_CERTIFICATE_VERIFY_FAILED, unable to get local issuer certificate`) ao requisitar o portal oficial por meio de biblioteca cliente HTTP em Python, malgrado o mesmo domínio ser acessível sem qualquer alerta por navegadores convencionais. A investigação da cadeia de certificação — validada por meio de inspeção direta do certificado emitido pela autoridade certificadora Sectigo para o domínio da Autoridade Portuária de Santos — revelou que o servidor de origem não transmite o certificado intermediário necessário à validação completa da cadeia de confiança. Navegadores modernos contornam essa omissão por meio de mecanismos de busca automática de certificados intermediários ausentes (AIA chasing), não implementados por padrão em bibliotecas cliente HTTP de propósito geral. Esse achado ilustra uma classe de falha de interoperabilidade que pode permanecer não detectada em ambientes de desenvolvimento cuja validação se restrinja à navegação manual, com implicação direta para a robustez de sistemas automatizados que dependam de fontes governamentais legadas.

4.3 Custo Operacional

Com base no consumo observado na execução de referência (2.048 MB de memória alocada, 70 segundos de duração, uma execução mensal), o consumo estimado de computação é de aproximadamente 143 GB-segundos por mês, valor substancialmente inferior ao limite gratuito de 400.000 GB-segundos mensais oferecido pelo provedor de nuvem para o serviço de computação serverless utilizado, confirmando a viabilidade econômica da arquitetura proposta para operação continuada em regime de nível gratuito.

4.4 Reconstrução da Série Histórica e Validação Empírica das Hipóteses de Análise

A execução do backfill histórico descrito na Seção 3.6 consolidou uma série de setenta e nove observações mensais (outubro de 2019 a maio de 2026) na camada gold, totalizando 8.860.902 registros de balança comercial (MDIC), 2.415 registros de movimentação portuária enriquecida por câmbio e 5.292 registros de origem geográfica agrícola. Esse volume permitiu, pela primeira vez neste trabalho, a avaliação empírica — ainda que preliminar — das hipóteses formuladas a priori na concepção do projeto.

4.4.1 Hipótese H1: Predominância da Sazonalidade sobre o Efeito Cambial

Medida	Coefficiente
Correlação de Pearson — volume físico exportado x PTAX (nível)	0,162
Correlação de Pearson — variação percentual mensal (volume x PTAX)	0,089
Correlação de Pearson — PTAX defasada em 1 mês x volume corrente	0,174
Coefficiente de variação sazonal médio (volume por mês do ano)	14,7%

Os coeficientes de correlação entre o volume físico de exportação e a cotação cambial (PTAX), tanto em nível quanto em variação percentual mensal e com defasagem de um mês, situam-se em faixa consistentemente baixa (0,09 a 0,17), indicando ausência de relação linear relevante entre câmbio e volume exportado no curto prazo, no período e na fonte avaliados. Em contrapartida, a agregação do volume mensal por mês do calendário, independentemente do ano, revela um padrão sazonal nítido, com pico em março (aproximadamente 11,5 milhões de toneladas) e vale em janeiro (aproximadamente 6,9 milhões de toneladas) — compatível com o calendário de colheita de soja no Centro-Sul do país. Esses resultados corroboram empiricamente a hipótese H1 formulada na concepção metodológica deste trabalho (Seção 3), sem que se possa, no entanto, descartar definitivamente um efeito cambial de magnitude reduzida ou de defasagem superior a um mês, não testada nesta etapa.

4.4.2 Hipótese H2: Divergência entre Volume Físico e Valor Financeiro Declarado

A comparação entre o volume físico mensal exportado pelo Porto de Santos e o valor FOB agregado das exportações brasileiras registradas pelo MDIC — ressaltando-se que a segunda série é de abrangência nacional, e não restrita ao Porto de Santos, constituindo uma limitação de comparabilidade explicitamente reconhecida — apresentou correlação de 0,762 em nível, e de 0,664 quando calculada sobre a variação percentual mensal de ambas as séries.

A divergência entre as duas medidas ilustra um risco metodológico relevante: a correlação em nível entre duas séries temporais que compartilham uma tendência de crescimento comum ao longo do período (2019-2026) tende a ser inflada por essa tendência compartilhada, independentemente de relação causal ou estrutural entre as variáveis — fenômeno classicamente descrito na literatura econométrica como correlação espúria de tendência. A correlação sobre variação percentual, menos suscetível a esse viés, ainda assim indica comovimento moderado a forte entre as duas séries, resultado esperado dado que o Porto de Santos representa parcela substancial do comércio exterior brasileiro, mas que não deve ser interpretado como validação plena da hipótese de reconciliação físico-financeira original, que pressupõe comparação no mesmo nível geográfico (porto a porto, não porto a país).

5 DISCUSSÃO E LIMITAÇÕES

Os resultados obtidos demonstram a viabilidade técnica da arquitetura proposta, porém um conjunto de limitações metodológicas deve ser explicitamente reconhecido, tanto por rigor científico quanto por constituir insumo direto para os trabalhos futuros descritos na Seção 6.

5.1 Modelo Estático de Alocação Geográfica Agrícola

A alocação de volume agrícola por unidade federativa, construída a partir do cruzamento entre a movimentação portuária e o boletim de safra da CONAB, baseia-se em um modelo de participação produtiva estática (share de produção por estado), sem consideração de restrições logísticas reais de escoamento — a exemplo da distância e da infraestrutura de transporte disponível entre estados produtores geograficamente distantes do litoral paulista e o Porto de Santos. Esse fato foi identificado e registrado no próprio sistema, por meio de mensagem de log explícita gerada durante a execução, constituindo exemplo de documentação de limitação metodológica no nível de código — prática recomendável, porém não substitutiva da necessária cautela interpretativa na leitura dos resultados dessa camada específica.

5.2 Cobertura Semântica Incompleta da Tabela de Correspondência De-Para

A tabela de correspondência entre mercadoria portuária e cultura agrícola (De-Para) não cobre a totalidade das mercadorias potencialmente agrícolas identificadas na movimentação da APS, com divergências registradas para as mercadorias 'Açúcar', 'Álcool' e 'Sucos Cítricos' na execução de referência. Essa lacuna não compromete a integridade das demais camadas do pipeline, mas limita a completude da camada de inteligência geográfica agrícola especificamente.

5.3 Camada de Apresentação por Views em Lugar de Modelagem Dimensional Física

O desenho original previa um esquema dimensional completo (star schema) para a camada gold, com tabelas de dimensão fisicamente segregadas para data, mercadoria, país e moeda. A implementação atual materializa o cruzamento entre fontes como tabelas fato únicas e desnormalizadas — na tabela de balança comercial, por exemplo, o nome do país e o código

completo da Nomenclatura Comum do Mercosul (NCM) são armazenados por extenso em cada uma das 8.860.902 linhas, em vez de referenciados por chave a dimensões próprias. Sobre essa base desnormalizada, foi construída uma camada de views SQL no Amazon Athena que resolve a necessidade imediata de consumo por ferramentas de Business Intelligence — pré-agregando totais mensais, rankings por país via função de janela e agrupamentos por capítulo NCM —, mas que não deve ser confundida com uma modelagem dimensional física: uma view de agregação reduz o volume de linhas retornado por consulta, ao passo que uma dimensão física reduz a redundância de armazenamento e formaliza hierarquias de atributo (por exemplo, capítulo, posição e subposição NCM como níveis explícitos de uma `dim_ncm`, em vez de recalculados a cada consulta via `SUBSTR` sobre o código completo). Dado que o Amazon Athena consulta dados em formato colunar (Parquet), a penalidade de desempenho por ausência de dimensões físicas é substancialmente menor do que seria em um banco relacional de linhas, o que constitui argumento legítimo para se avaliar, como trabalho futuro, se a modelagem dimensional completa é estritamente necessária para os casos de uso analíticos atuais, ou se a camada de views já supre a necessidade prática de consumo, restando a normalização física como ganho de governança e hierarquia semântica, não de desempenho.

5.4 Alcance e Limites da Validação Estatística Realizada

A reconstrução da série histórica descrita na Seção 4.4 permitiu testar empiricamente, com setenta e nove observações mensais, a hipótese de predominância sazonal sobre o efeito cambial (H1), com resultado favorável à hipótese (correlações entre 0,09 e 0,17, sazonalidade com coeficiente de variação de 14,7%), superando a limitação apontada em versão anterior deste trabalho, quando a série disponível ainda não alcançava o mínimo de vinte e quatro observações mensais considerado necessário para inferência preliminar. Ressalva-se, contudo, que os testes de correlação aplicados são bivariados e não controlam por variáveis de confusão potencialmente relevantes — como preço internacional da commodity ou capacidade de escoamento logístico —, de modo que os resultados devem ser interpretados como evidência direcional, não como prova de ausência de relação causal entre câmbio e volume. Adicionalmente, a hipótese H2 (Seção 4.4.2) permanece apenas parcialmente avaliável com os dados atualmente disponíveis, em razão da incompatibilidade de abrangência geográfica entre a série física (Porto de Santos) e a série financeira (Brasil, âmbito nacional) — limitação estrutural que persistirá até que uma fonte de valor financeiro desagregada por porto de embarque seja incorporada ao pipeline.

5.5 Integração Pendente com a Agência Nacional de Transportes Aquaviários

A comparação de participação de mercado entre o Porto de Santos e demais portos brasileiros, planejada por meio da integração com o painel estatístico da ANTAQ, permanece pendente de implementação, em razão de instabilidade observada na interface de consulta da fonte durante o período de desenvolvimento — sinalizada no código do sistema como item em aberto ('trabalho em progresso'), e não como funcionalidade ausente por omissão.

5.6 Gestão de Segredos de Configuração

A URL do webhook de notificação do Slack é atualmente definida por variável de ambiente na configuração de implantação, prática adequada para desenvolvimento, porém reconhecidamente inferior ao uso de um serviço dedicado de gestão de segredos (AWS Secrets Manager) para ambiente de produção continuada — lacuna documentada explicitamente nos comentários do próprio arquivo de infraestrutura como código, e não silenciosamente ignorada.

5.7 Ausência de Mecanismo de Retomada Automática do Backfill

O orquestrador de backfill histórico (Seção 3.6) processa a totalidade dos períodos em uma única execução sequencial, sem persistência de ponto de controle (checkpoint) entre lotes mensais. Em caso de interrupção da execução completa — por falha de ambiente, esgotamento de cota de alguma fonte externa ou intervenção manual —, a retomada exige a alteração manual do parâmetro de início do backfill para o próximo período não processado, identificado por inspeção do data lake. Essa limitação é aceitável para uma operação de reconstrução histórica de execução única, mas constitui risco operacional caso o mesmo padrão venha a ser reaproveitado para reprocessamentos parciais recorrentes, cenário não contemplado no desenho atual.

5.8 Cobertura Irregular da Camada de Origem Agrícola por Inconsistência da Fonte CONAB

A inspeção da tabela fato de origem agrícola consolidada revelou ausência completa de registros para os anos de 2022 e 2024, em contraste com a cobertura integral observada nas demais tabelas fato do mesmo backfill (balança comercial e movimentação cambial, ambas com

as oito safras anuais representadas). Ao contrário do que se cogitou preliminarmente, a causa dessa lacuna não reside em falha do pipeline, mas em inconsistência de publicação da própria fonte primária: os boletins de safra da CONAB referentes a esses períodos encontram-se sinalizados pela plataforma da instituição como "conteúdo restrito" no momento da consulta automatizada, inacessíveis à extração programática independentemente da correção do código cliente. Adicionalmente, identificou-se, para o ano de 2023, a publicação de dois boletins distintos como referência para o mesmo ano-safra — ambiguidade de fonte que reforça a decisão, descrita na Seção 3.2, de tratar a CONAB como fonte opcional na arquitetura do pipeline, em vez de sujeitá-la aos mesmos mecanismos de circuit breaker aplicados às demais fontes. Diferentemente das falhas de extração identificadas para a fonte da APS (Seção 4.2.1), portanto, esta lacuna não é corrigível por ajuste de engenharia no lado do pipeline, estando condicionada exclusivamente à eventual regularização de publicação pela própria CONAB.

6 CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS

Este trabalho demonstrou a viabilidade técnica e econômica de um pipeline serverless para extração, validação e reconciliação de dados públicos heterogêneos de comércio exterior, tomando como estudo de caso a movimentação portuária de Santos. Os objetivos específicos definidos na Seção 1.2 foram integralmente atendidos: implementou-se um mecanismo de extração resiliente a variações de formatação documental, corrigido empiricamente após a identificação de uma falha sistemática de inferência tabular; estabeleceram-se contratos de dados formais capazes de bloquear a propagação de dado estruturalmente inválido; projetou-se e implementou-se um mecanismo original de controle de qualidade sensível à representatividade econômica dos registros rejeitados, e não apenas à sua contagem; avaliou-se e justificou-se empiricamente a escolha de uma arquitetura serverless sem provisionamento de rede privada, com custo operacional compatível com o nível gratuito de utilização; e documentaram-se, de forma reproduzível, as decisões de arquitetura e as descobertas técnicas obtidas.

A reconstrução de uma série histórica de oito anos, discutida nas Seções 3.6 e 4.4, permitiu avançar de um trabalho de natureza essencialmente arquitetural para um trabalho com capacidade analítica preliminar: a hipótese de predominância sazonal sobre o efeito cambial de curto prazo (H1) encontrou suporte empírico direto, enquanto a hipótese de reconciliação físico-financeira (H2) revelou uma limitação estrutural de comparabilidade geográfica que não havia sido antecipada na formulação inicial das hipóteses. Esse resultado ilustra, em si, um valor metodológico do trabalho: a disponibilidade de mais dado não apenas confirma ou refuta hipóteses, mas frequentemente revela premissas implícitas — no caso presente, a suposição tácita de que os dados do MDIC seriam diretamente comparáveis aos da APS — que só se tornam visíveis quando confrontadas com volume suficiente de observação empírica.

Como trabalhos futuros, recomenda-se: (i) a avaliação criteriosa de custo-benefício entre a normalização física completa da camada gold em esquema estrela e a manutenção do modelo atual de tabelas fato desnormalizadas com camada de views agregadas, tendo em vista que o formato colunar do Athena atenua o ganho de desempenho tradicionalmente associado à normalização dimensional, restando como principal benefício a governança semântica de hierarquias de atributo; (ii) a integração da Agência Nacional de Transportes Aquaviários, uma vez estabilizada sua interface de consulta; (iii) a incorporação de um mecanismo formal de gestão de segredos para as credenciais de notificação; (iv) o monitoramento periódico da

regularização de publicação dos boletins da CONAB para os anos de 2022 e 2024 (Seção 5.8), com reprocessamento direcionado desses períodos assim que o conteúdo deixar de estar sinalizado como restrito pela fonte, e a avaliação de fontes secundárias de dado de safra como alternativa de contingência; (v) a implementação de um mecanismo de checkpoint para o orquestrador de backfill, permitindo retomada automática de execuções interrompidas; (vi) a incorporação de uma fonte de dados de valor financeiro desagregada por porto de embarque, de modo a viabilizar a validação plena da hipótese H2 no mesmo nível geográfico da série física; e (vii) a expansão do modelo de alocação geográfica agrícola para incorporar restrições logísticas reais, em substituição ao modelo estático de participação produtiva atualmente empregado.

REFERÊNCIAS

AMAZON WEB SERVICES. AWS Lambda Developer Guide. Seattle: AWS, 2024. Disponível em: <https://docs.aws.amazon.com/lambda/>. Acesso em: 14 jul. 2026.

AMAZON WEB SERVICES. Serverless Data Analytics Pipeline Reference Architecture. Seattle, 2026. Disponível em: <https://aws.amazon.com/pt/solutions/serverless-data-analytics-pipeline/>. Acesso em: 17 jul. 2026.

ASSOCIAÇÃO NACIONAL DOS CENTROS DE PÓS-GRADUAÇÃO EM ECONOMIA (ANPEC). Panorama do comércio exterior brasileiro: ganhos setoriais e competitividade. Anais do 52º Encontro Nacional de Economia, [S.l.], v. 42, p. 1-18, 2024.

AUTORIDADE PORTUÁRIA DE SANTOS. Mensário Estatístico. Santos: APS, 2026. Disponível em: <https://www.portodesantos.com.br/informacoes-operacionais/estatisticas/mensario-estatistico/>. Acesso em: 14 jul. 2026.

BANCO CENTRAL DO BRASIL. API de Dados Abertos - PTAX (Cotação de Moedas). Brasília, 2026. Disponível em: <https://dadosabertos.bcb.gov.br/>. Acesso em: 17 jul. 2026.

COMPANHIA NACIONAL DE ABASTECIMENTO. Boletim da Safra de Grãos. Brasília: CONAB, 2026. Disponível em: <https://www.gov.br/conab/pt-br/atuacao/informacoes-agropecuarias/safras>. Acesso em: 14 jul. 2026.

DATABRICKS. What is the Medallion Lakehouse Architecture? San Francisco, 2026. Disponível em: <https://www.databricks.com/glossary/medallion-architecture>. Acesso em: 17 jul. 2026.

DELTA LAKE. Building the Medallion Architecture with Delta Lake. [S.l.]: Linux Foundation, 2026. Disponível em: <https://docs.delta.io/latest/medallion-architecture.html>. Acesso em: 17 jul. 2026.

EAGAR, Gareth. Data Engineering with AWS: design and build scalable data pipelines. Birmingham: Packt Publishing, 2023.

KRUGMAN, Paul R.; OBSTFELD, Maurice; MELITZ, Marc J. Economia Internacional: teoria e política. 10. ed. São Paulo: Pearson, 2015.

LIPP, Brian. Modern Data Architectures with Python: build scalable and robust data pipelines. [S.l.]: O'Reilly Media, 2024.

MINISTÉRIO DO DESENVOLVIMENTO, INDÚSTRIA, COMÉRCIO E SERVIÇOS (MDIC). Comex Stat - Estatísticas de Comércio Exterior Brasileiro. Brasília, 2026. Disponível em: <https://comexstat.mdic.gov.br/>. Acesso em: 17 jul. 2026.

NYGARD, Michael T. Release It!: design and deploy production-ready software. 2. ed. Raleigh: Pragmatic Bookshelf, 2018.

PDFPLUMBER. pdfplumber: Plumb a PDF for detailed information. [S.l.], 2026. Disponível em: <https://pdfplumber.readthedocs.io/>. Acesso em: 17 jul. 2026.

PYDANTIC. Pydantic Documentation. 2026. Disponível em: <https://docs.pydantic.dev/>. Acesso em: 14 jul. 2026.

RAMALHO, José Antônio; NEVES, Julio Cesar. Extração de Dados de Documentos Não Estruturados: técnicas e aplicações. São Paulo: Novatec, 2021.

SANTOS, Ana. Extraíndo dados de PDFs com PdfPlumber usando Python: um guia prático para tabelas complexas. Medium, 2025. Disponível em: <https://medium.com/@analytics/pdfplumber-python-pdf-extraction>. Acesso em: 17 jul. 2026.

SARKAR, Aniruddha. Ultimate AWS Data Engineering: from foundations to advanced solutions. [S.l.]: Apress, 2025.

SILVA, João; PEREIRA, Maria. Performance logística do Brasil no comércio internacional: uma análise comparativa de infraestrutura. Revista Brasileira de Logística e Transportes, São Paulo, v. 18, n. 1, p. 112-130, jan./jun. 2025. Disponível em: <https://www.redalyc.org/>. Acesso em: 17 jul. 2026.

VAN DER AALST, Wil M. P.; BICHLER, Martin; HEINZL, Armin. Robotic Process Automation. Business & Information Systems Engineering, v. 60, n. 4, p. 269-272, 2018.